


โจทย์คัดเลือกผู้สมัครโครงการ Innosoft Student Associate Program ในสายงาน Data Engineer

ศูนย์นวัตกรรมซอฟต์แวร์และการประมวลผล (Innosoft) ได้รับมอบหมายจากหน่วยงานรัฐแห่งหนึ่ง ให้รวบรวมข้อมูลที่เกี่ยวข้องกับกำลังพลภาครัฐของสำนักงาน ก.พ. และผลการเบิกจ่ายของกรมบัญชีกลาง โดยปัญหาที่พบ คือ แหล่งข้อมูลทั้งสองนั้นเผยแพร่อยู่ในเว็บไซต์ในรูปแบบ Excel File ดังนี้

ข้อมูลกำลังพลภาครัฐ

<https://www.ocsc.go.th/strategy-policy-work-plan/reports-statistics/government-workforce-statistics-report/2021-present-workforce-statistics/>



ผลการเบิกจ่ายเงิน

<https://www.cgd.go.th/cs/internet/internet/%E0%B8%82%E0%B9%88%E0%B8%B2%E0%B8%A7%E0%B8%AA%E0%B8%96%E0%B8%B4%E0%B8%95%E0%B8%B4.html>



ช่วงเวลา	จำนวนเงิน	วันที่	จำนวนเงิน
ผลการเบิกจ่ายเงินงบประมาณ 10 ปี	ผลการเบิกจ่ายเงิน ณ วันที่ 3 กรกฎาคม 2569	03/07/2569	255
ผลการเบิกจ่ายเงิน ณ วันที่ 3 กรกฎาคม 2569	ผลการเบิกจ่ายเงิน ณ วันที่ 3 กรกฎาคม 2569	03/07/2569	255
ผลการเบิกจ่ายเงิน ณ วันที่ 26 มิถุนายน 2569	ผลการเบิกจ่ายเงิน ณ วันที่ 26 มิถุนายน 2569	26/06/2569	485

โจทย์ (คะแนนเต็ม 120 คะแนน)

1. สํารวจชุดข้อมูลทีเผยแพร่ล่าสุดของทั้งสองแหล่งข้อมูล แล้วออกแบบ Data Warehouse ที่คิดว่าเหมาะสมสำหรับเก็บข้อมูลทั้งสองชุดนี้ สํารับส่งต่อให้ Data Analyst เอาไปใช้วิเคราะห์ข้อมูลต่อไปได้ สะดวก พร้อมอธิบายเหตุผลว่า เพราะเหตุใดจึงออกแบบเช่นนั้น (การออกแบบ 10 คะแนน / การอธิบายเหตุผล 10 คะแนน / รวม 20 คะแนน)
2. สํารวจข้อมูลแต่ละชุด (EDA & Data Profiling) และอธิบายปัญหาที่ปรากฏบนชุดข้อมูลแต่ละชุด (ชุดละ 10 คะแนน / รวม 20 คะแนน)
3. ต้องการให้ท่านสร้าง Automate Data Pipeline เพื่อเป้าหมายดังนี้ (รวม 60 คะแนน)
 - a. ดึงข้อมูลชุดล่าสุดของแต่ละแหล่งข้อมูลออกมา จัดการ Data Preparation เพื่อแก้ปัญหาที่เจอในข้อที่ 2 และจัดเก็บข้อมูลเหล่านั้นบน Data Warehouse ที่ออกแบบไว้ตามข้อ 1 (extraction 15 คะแนน / cleaning 15 คะแนน / loading 5 คะแนน / code quality 5 คะแนน / รวม 40 คะแนน)
 - b. ทุกเดือนต้องมีการ ตรวจสอบว่า มีชุดข้อมูลใหม่ถูกเผยแพร่ออกมาบนแหล่งข้อมูลทั้งสองนี้หรือไม่ (10 คะแนน)
 - c. หากมีชุดข้อมูลใหม่เผยแพร่มา (บนสมมติฐานว่า มีโครงสร้างเหมือนชุดข้อมูลล่าสุดนี้) ให้สามารถดึงข้อมูลมาเก็บไว้ได้โดยไม่มีปัญหา (10 คะแนน)
4. ในฐานะ Junior Data Engineer ท่านอยากเสนอแนะอะไรแก่ Senior Data Engineer ของโครงการนี้ เพื่อเสนอแนะให้โครงการนี้ดำเนินการไปได้สำเร็จลุล่วง (20 คะแนน)
5. ขอให้จัดทำ source code ทั้งหมด จัดเก็บอยู่ใน Github Repository และ Demo การทำงานของ Automate Data Pipeline ที่ทำ ในวันสัมภาษณ์
6. ใช้ AI ช่วยได้ แต่ต้องอธิบาย code ทุกส่วนได้ในวันสัมภาษณ์

ขอให้ท่านโชคดี
และพบกัน

